IFT3700 Devoir 2

Question 1 (30%)

Imaginez que vous devez traiter des données de nature astronomique. Il s'agit de données sous forme de table concernant 7300 milliards d'étoiles. Pour chaque étoile la table contient la position dans l'espace 3D (3 FLOAT64), la luminosité apparente de l'étoile (1 FLOAT32) et sa catégorie représentée par un entier entre 1 et 10 (1 INT8) et un vecteurs de 23 caractéristiques physiques (23 FLOAT32). La

taille des données qui sont stockées de façon efficace dépasse le 900 Téraoctets. Les données sont réparties de façon balancée sur 1200 serveurs avec un processeur rapide, 128 Gigaoctets de mémoire vive et utilisant chacun un disque SSD de capacité 4 Téraoctets et de vitesse de lecture et écriture de 3 Gigaoctets/sec. La communication entre les serveurs s'effectue à une vitesse de 1 Gigaoctets/sec.

Proposez une approche distribuée qui permet de répondre aux questions suivantes et expliquez en détail toute la démarche permettant leur résolution.

Nous savons qu'un algorithme qui prend en argument une table d'étoiles (pour être plus précis les positions des étoiles en x,y,z) retourne les 1000 paires les plus proches d'étoiles en O(n log n). O(n log n) étoilesPos[(x,y,z), ...]

A. Trouvez les 1000 paires d'étoiles les plus proches en termes de distance euclidienne. Recherche des deux points les plus rapprochés

closestPairs() Nous utiliser cet algorithme comme une boîte noire. Puisque les étoiles dans nos serveurs ne sont pas triées, il est possible qu'il existe une étoile a dans un serveur B, tel que la distance de la paire(a,b) est plus petite que les meilleures paires trouvées par l'algorithme dans le serveur A et le serveur B sépéarement. En effet, le seul moyen de trouver cette paire(a,b) et d'utiliser l'algorithme sur A+B.

enfin closestPairs(1+4).

Le défi étant ici qu'il existe pas deux serveurs, mais 1200. Et il faut comparer tous ces serveurs là un à un pour être sûr de manquer aucune paire. Évidemment, nous sommes limités par la puissance de notre serveur (Capacité, vitesse de lecture etc). La question est alors : Quel est la méthode la plus rapide pour comparer tous nos serveurs un à un tout en respectant la capacité de nos serveurs. Nous avons penser à un algorithme simple que nous alons prendre le temps d'expliquer.

Cela dit, comme nous avions expliqué, ce n'est pas suffisant, il faut comparer les serveurs un à un aussi. Donc, nous voulons rouler closestPairs(1), mais aussi closestPairs(1+2), closestPairs(1+3) et

Mise en contexte Bon, avant de rentrer dans les détails, expliquons l'essence de notre idée. Ademttons que nous avons un certains nombre de serveurs. pour illustrer disons 4. Donc, nous avons les serveurs {1,2,3,4} et chacun de nos serveur contient une table d'étoiles. Biensûre en parallèle, tous les serveurs peuvent appliquer closestPairs().

1. Premier temps : closestPairs() sur la table i de chaque serveur i en parallèle (où $i \in \{1,2,3,4\}$) 2. Deuxième temps : Envoyer la table 1 dans le serveur 2

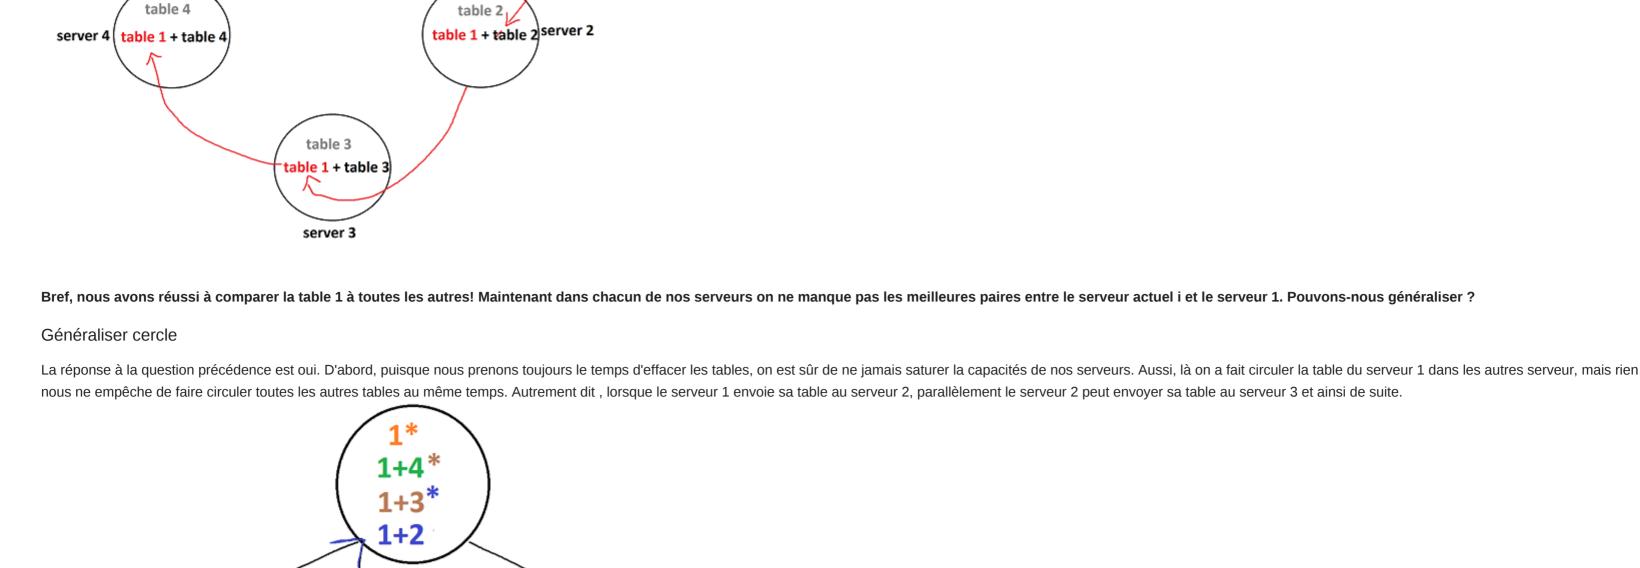
L'idée que nous avons eu était de faire circuler la table de manière circulaire. Donc :

3. Troisième temps : rouler closestPairs(table1 + table2) et biensûre on garde les meilleures paires 3. Troisième temps : On commence à envoyer la table 1 au serveur 3 4. Quatrième temps : On supprime la table 1 du serveur 2 lorsqu'elle a fini d'être copié au serveur 3

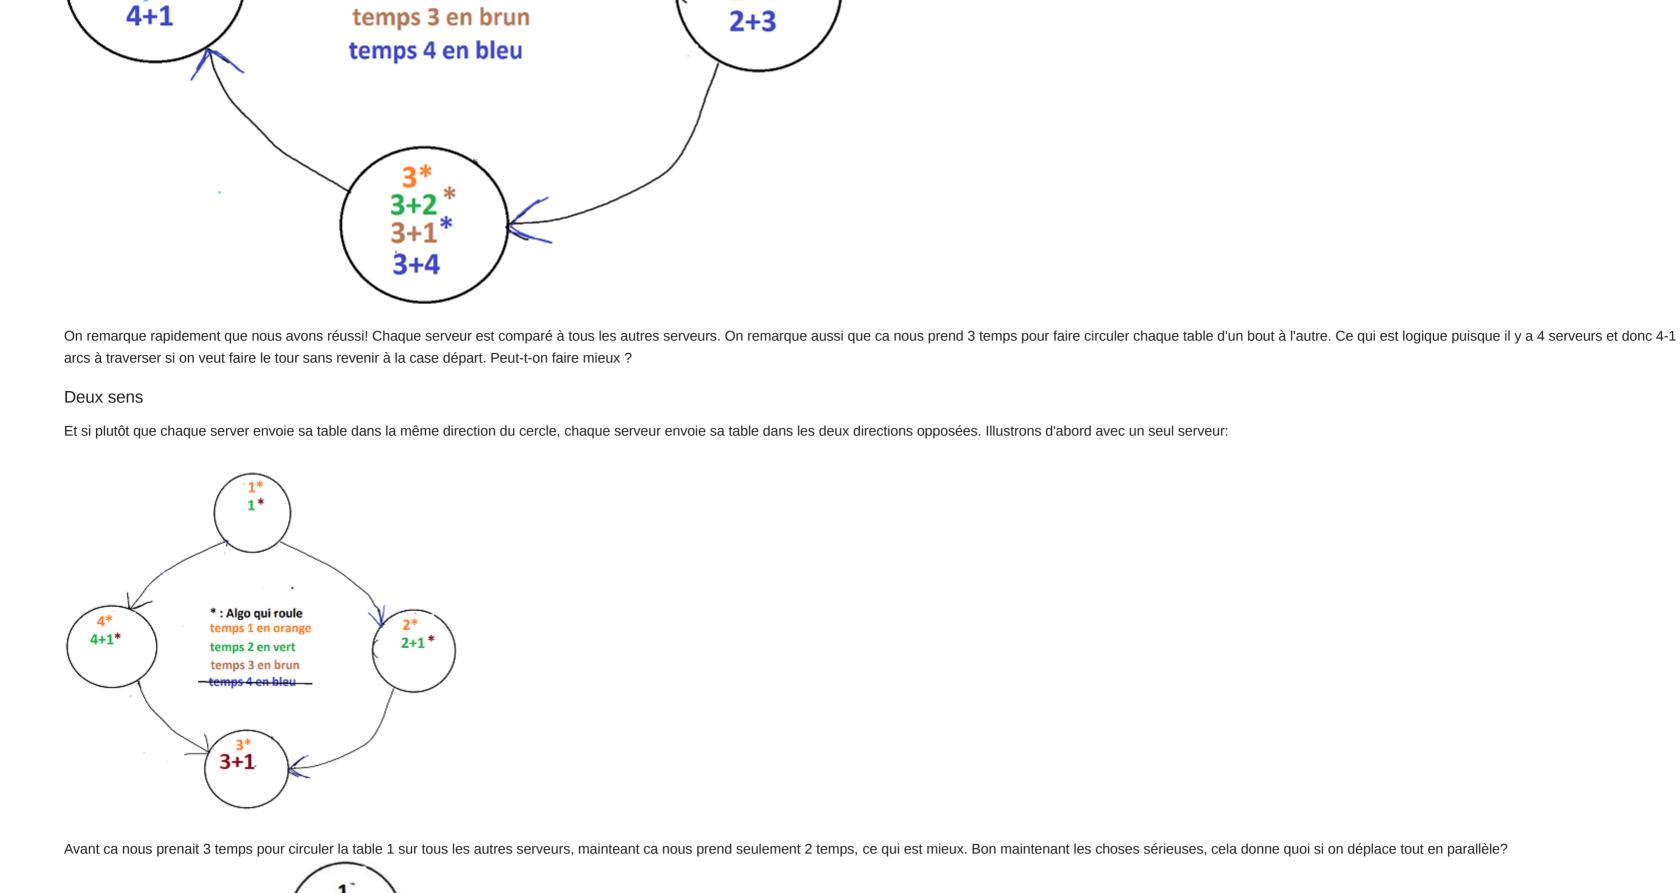
5. On recommence ce qu'on a fait plus haut (soit closestPairs(table 1 + table3) et ainsi de suite ...)

server 1

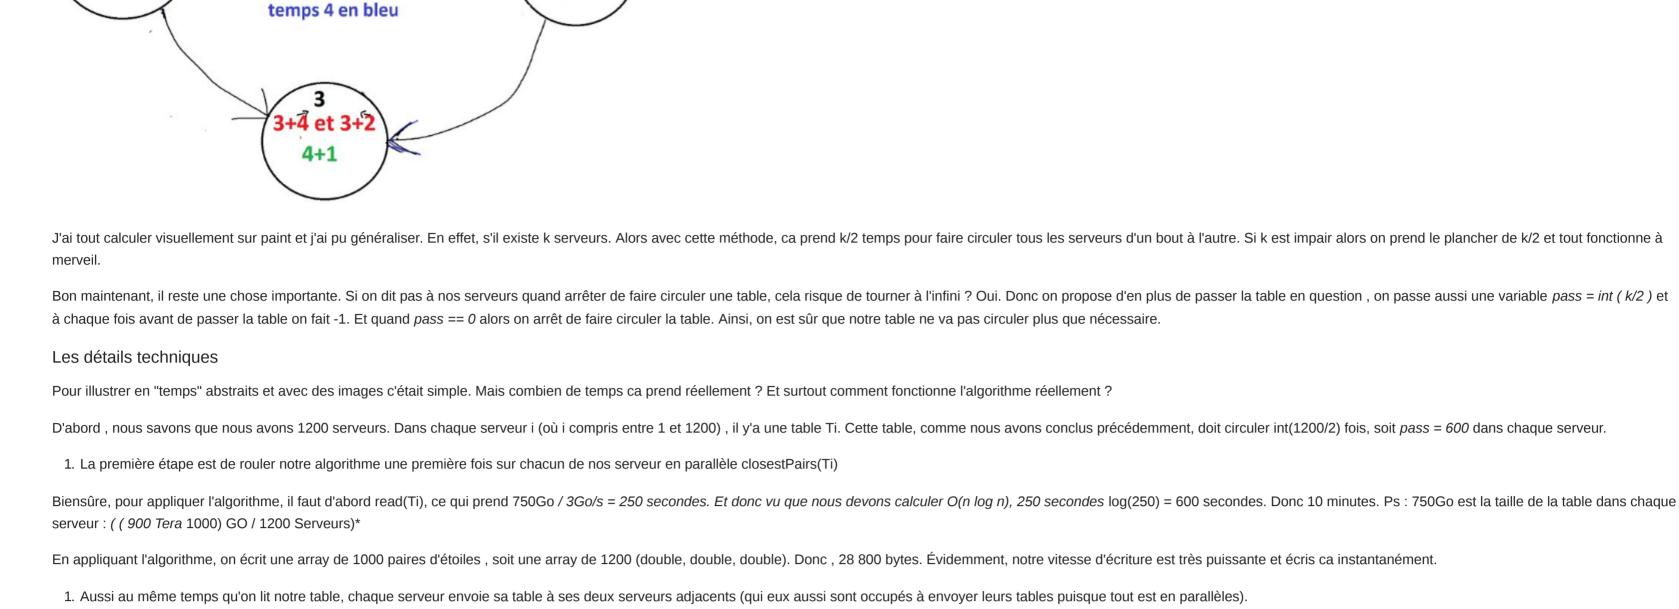
table 1 inutile de comparer 1 à 1 donc on arret ici



* : Algo qui roule temps 1 en orange temps 2 en vert



1+3



Biensûre, on répète les étapes 2 et 3 jusqu'à ce que chaque table aura traverser 600 serveurs (donc tous les pass==0).

Position

(1999.0, 28928.0, 3131.0) (3485.0, 19211.0, 2992.0)

Nous savons d'ailleurs que les données (les tables) sont déjà assignées aux serveurs.

Table1[]

Table2[]

Au niveau du temps, cela donne : 50 minutes + 599 * (50 minutes + 8 minutes) = 34 782 minutes. **Donc environ 24 jours**. Ce qui est moins que 30 jours.

Catégorie

* type 1 1

* t. 2 1 * t.3 1

* t.3 1

* : Algo qui roule temps 1 en orange

temps 2 en vert temps 3 en brun

2+4

4+1,4+

Index étoile

0

1

for étoile in Table[Étoiles]:

S [toile.getCatégorie] += 1

Étape 1

return S

Input

Table1[]

Table2[]

Biensûre, puisque nous devons read(750Go 2 2), cela va prendre 3000Go/ 3Go/s = 1000 secondes. Donc en O(n log n), 1000* log (1000) = 3000 secondes. Soit 50 minutes. Au même temps, l'algorithme met à jour instantanément nos 1000 meilleures paires. 1. Lorsque nous sommes en train de lires les tables, nous pouvons déjà commencer à transférer les table (50 minutes). Puisque on le fait en parallèle (heureusement) les temps ne s'additionne pas. Donc seulement 50 minutes pour l'étape 2. 1. Une fois les tables transéférées , on doit les delete des anciens serveurs pour faire de la place à de nouvelles tables.

La taille de chaque table comme discuté précédemment est de 750 GO calculé avec ((900 Tera 1000) GO / 1200 Serveurs)*. Il suffit d'une lecture en O(n) sur un serveur pour savoir il y'a combien d'étoiles dans chacune des catégories avec un algorithme comme

Output

*type 1 3

* t. 2

D'abord on envoie pas seulement la table, mais un tuple (pass--, Table i) pour savoir combien de fois chaque table est passée. Aussi, puisque la vitesse de communcation entre les serveurs est de 1Go par seconde, cette vitesse doit être dévisée par 4 puisque

chaque serveur envoie sa table à deux serveurs et chaque serveur recoit une nouvelle table de deux autres serveurs. Donc, la vitesse est de 250Mo/s. Puisque nous avons 750Go à déplacer, donc cela nous prend 3000 secondes, soit 50 minutes.

1. Après chaque fin de communication, on read les nouvelles tables pour appliquer closestPairs(Ti +). Donc chaque serveur doit appliquer l'algo sur sa propre table + la table recu du serveur à gauche. Aussi sur son algo + table recu de la droite.

Une dernière note: D'abord, nous avions calculé que chaque disque dur occupe seulement 18,75% de l'espace (750Go/ 4 Tera). Cela a permis notre circulation de tables dans les serveurs puisque nous manquons jamais d'espace (à condition biensûr d'effacer les tables au fur et à mesure). De plus, puisque on lit toujours tout directement sur le disque dur, on ne sature jamais la mémoire vive. En effet, lorsque nous avons fais nos calculs pour l'algorithme, nous avons lu directement sur le disque dur en temps O(n log n). Sur la mémoire vive ca aurait été instantané, mais la gestion de la mémoire aurait été très difficile vu la taille de nos données.

On veut supprimer 750Go * 2, ce qui se fait en 500 secondes. Soit 8 minutes. On ne fait pas cette étape en parallèle puisque ca va revenir au même, vu qu'on va ralentir l'écriture des nouvelles tables.

B. Compter combien d'étoiles il y a dans chaque catégorie. Mise en contexte Énoncé : Pour chaque étoile la table contient ... et sa catégorie représentée par un entier entre 1 et 10 (1 INT8). Nous avons 7300 milliards d'étoiles au total répartis à travers 1400 serveurs.

2 (9425.0, 39211.0, 5992.0) 5 214 285 714 (9425.0, 59211.0, 1992.0)

Donc, nous avons environ 5 milliards d'étoiles dans chaque serveur. Chaque entrée dans la table dans un serveur représente une étoile. Et pour chaque entrée la même colonne donne la catégorie de l'étoile.

le suivant: CompterCatégories(Table[étoiles]): S = initializes array of length 10 filled with 0's

*t.1 3

* t. 2 2

le temps estimé pour cette étape est de O(n) puisque nous allons lire les n entrées de la table de tous les serveurs parallèlement. Ce qui risque de prendre le plus de temps est probablement la lecture des données. On va assumer que notre algorithme est vraiment naif et lit chaque entrée au complet au lieu de lire simplement les catégories. Donc, pour lire toutes les entrées (750GO) nous avons besoin de 750GO/ 3Go par seconde = 250 secondes. Soit 4 minutes environ. Enfin, l'écriture se fait au même temps

que la lecture et nous allons assumer que l'écriture dans le tableau S se fait instanténement dans chaque serveur puisque nous devons écrire un int dans un tableau de taille 10 à chaque fois et vu notre vitesse d'éciture ce n'est vraiment pas un problème.

Maintenant que chacun de nos 10 premiers serveurs contient une donnée (du tableau), nous voulouns les combiner dans un seul tableau de taille 10. La manière la plus simple est de créer un tableau dans le serveur 1. Catégories Comptés = []. Ensuite, on peut déjà mettre dedans la variable Catégorie_1 comme suit Catégories Comptés.append(Catégorie_1). Maintenant il suffit que nos 9 autres serveurs envoie leur données Catégorie_i et chacunes des données va être append au tableau comme suit Catégories Comptés. append (Catégorie_i). Bref à la fin , ce tableau est notre réponse finale. Soit la somme totale de toutes les catégories. Encore une fois tout cela prend seulement quelques secondes (instantané) puisqu'il

3. Les 10 premiers serveurs font la somme de ce qu'ils recoivent des autres serveurs et store ca dans var Catégorie_i (Bref, chaque serveur server i (i compris entre 1 et 10) aura une variable Catégorie_i qui est la somme des S[i] des 1200serv.)

D'abord, notre colonne catégorie c'est le label (y) et que la colonne caractéristique sont les données sur lesuqlles on se base pour classifier. (Pour faire un parallèle avec Mnist, les chiffres c'est les catégories et les vecteurs pixels sont les vecteurs

De plus, il est clair que si ensuite un serveur recoit une requete avec un vecteur caractéristique, il est capable d'utiliser le "modèle" plus haut, pour prédire la catégorie de l'étoile. En effet, il calcule la distance de ce vecteur à tous les vecteurs dont on connait la

En d'autres mots, si chaque serveur contient sa table et on envoie une requête à chaque serveur avec une grande table, la

Catégorie

3

Donc, si nous avons un tuple de ce type : (catégorie, vecteur de caractéristiques) , soit un (int, [double 23]) alors la taille de ce tuple est : 4 bytes + 8 bytes 23 = 188 bytes. Soit 0,188 kilobyte.

4. Le premier serveur crée une table CatégoriesComptés[] de taille 10. Il append dedans tous les Catégorie_i des 10 serveurs). (En effet,il commence par append.Catégorie_1, ensuite Catégorie_2 ... Catégorie_10. À la fin ce te tableau est notre résultat)

C. Produisez un classifieur qui, étant donné le vecteur de caractéristiques (23 nombres réels), prédit la catégorie de l'étoile. Il est important que votre classifieur utilise une technique

Caractéristique $(2.4, 1.1, \dots 9.2)$

 $(3.2, 9.9, \dots 1.8)$

(2.4, 1.1, ... 9.2) (3.2, 9.9, ... 1.8)

caractéristique)

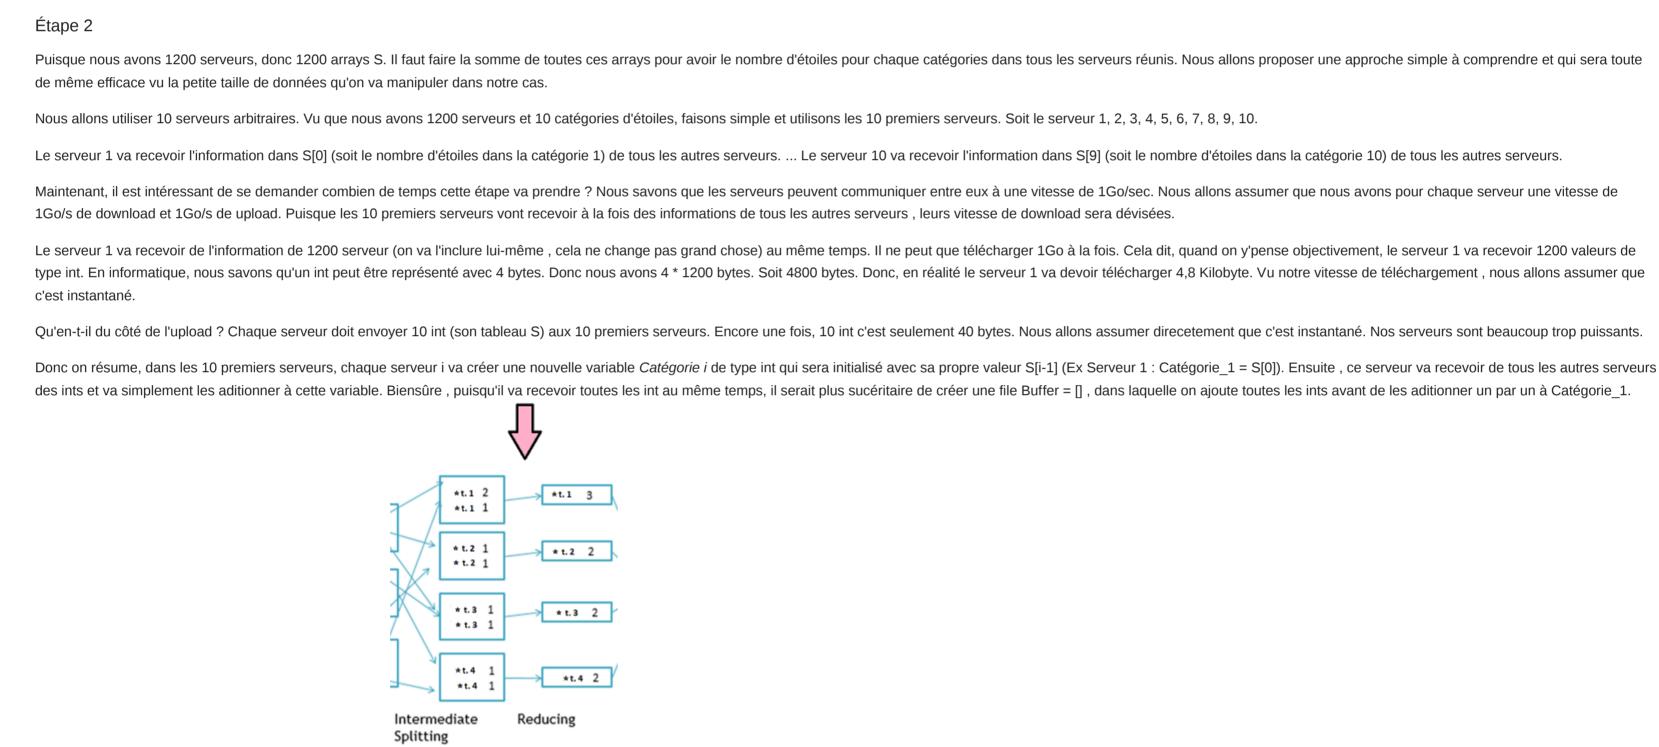
*t.1 2

*t.1 1

* t. 2 1

* t. 2 1

*t.4 1 * t.3 2 Table3[] * t. 2 1/ * t.3 1 *t.4 2 * t.3 2 Table3[] * t.3 1 *t.1 2 *t.4 1 *t.4 1 *t.4 2 *t.4 1 Mapping Splitting Intermediate Combining Reducing Splitting Notation: * t. 1 -> Catégorie de l'étoile est 1 Ainsi, à la fin de notre calcul en parallèle, chaque serveur aura une array d'une taille de 10 int. Chaque élément dans ce tableau peut être lu comme suit : S[0]=(étoile de catégorie 0, nombre d'étoiles de type 0), ..., S[i] (Étoile de Catégorie i, # d'étoiles de catégorie i).



* t. 2 2 * t.3 2 *t.4 2 1.3 2 rt.4 2 Combining suffit de déplacer une très petite quantitée d'informations au serveur 1. Tout cela nous aura pris moins de 5 minutes. Algorithme résumé en quelques lignes: 1. appeler l'algorithme CompterCatégories(Table[étoiles]) -> S [nombre de catégorie] sur chaque serveur en parallèle 2. Tous les serveur en parallèle envoie S[catégorie] au Serveurs.catégorie. Ex: S[1] de tous les serveurs envoyé au serveur 1.

de calcul distribué soit pendant l'entraînement et/ou lors de la prédiction.

Index étoile

64-bit Size

2 bytes

4 bytes

4 bytes

8 bytes

D'abord, il est clair que chaque serveur peut lire la table sur le disque en O(n) & 3Go/s . Pour ainsi produire T:

requete ((2.4, 1.1, ... 9.2)

1 3

2 2

Output

*type1 3

Même si on fait cela, ca ne va pas impacter notre temps.

Étape 3

Mise en contexte

caractéristiques).

4 bytes

Type Name

short

float

Data Types and Sizes

D'abord , à quoi ressemblent nos tables ?

KNN (Ou n'importe quel classifieur)

Dans un classifieur comme KNN, comment allons nous procéder?

32-bit Size

2 bytes

4 bytes

4 bytes

8 bytes

Server i Index étoile Catégorie Rien d'autre qu'une table

catégorie et on choisit une catégorie selon k. Biensûre cela se fait encore une fois en O(n) en lisant T directement sur le disque. Questionnements Si on veut prédire la catégorie d'une étoile avec une requête(caractéristiques[doubles*23]), comment prédire cette catégorie le plus rapidement possible? On L'envoie à un seul serveur au hasard? À plusieurs serveurs en parallèle et selectionner la catégorie la plus souvent prédite? Y'a-t-il un moyen d'accélérer , par exemple en évitant de comparer à toutes les étoiles de T? De plus, lors de la création de T, peut-t-on améliorer T? Autrement dit y ajouter des étoiles pour que T soit plus précis. Par exemple, si le serveur 2 crée T2, est-ce une bonne idée de combiner T1+T2? Si oui comment procéder pour combiner un maximum de tables en parallèles? Réponses D'abord, inuitivement, plus notre modèle est "petit", moins de temps ca prendera pour prédire la catégorie d'un vecteur caractéristiques c. En effet, si nous avons un serveur A avec une table T1 avec n d'étoiles connues, alors pour pour prédire c, nous devons le comparer à tous les n de T1. Cela va se faire en n temps. Cela dit, si nous avons une table T1 du serveur 1 et une table T2 du serveur 2 combinées, soit T1+T2= T12, alors prédire la catégorie de c dans T12 nous prendera 2n temps. Aussi, il est clair que plus que notre "modèle" est grand, plus on aura de précision dans la prédiction. Reprenons l'exemple avec deux serveur 2 prododuit table T1 et serveur 2 prododuit table T2. Donc, essayer de prédire la catégorie de c sur T1 ou sur T2 sera moins précis que de prédire c sur T1+T2 (T12).

réponse sera plus lente, mais de meilleure précision.

1200

base

Pourquoi?

1152

1024

16

plusieurs petites tables, les calculs se feront plus vite et en parallèle.

Une table à n entrée (chaque étoile) avec d dimensions (caractéristiques). Nous avons donc n * d.

important de ne pas combiner beaucoup trop de tables.

Calcul de la taille d'une Table

128

Est ce que nous pouvons faire un mélange des deux ? Oui, on crée un certains nombre de "super" tables. Ensuite, on envoie nos requetes de prédictions à toutes ces super tables en parallèle. Lorsqu'on a nos prédiction, on garde la prédiction qui revient le plus souvent comme étant la meilleure. Super Tables D'abord, re définissons plus rigoureusement ce qui est une super table dans notre contexte. Pour cela rappelons qu'un serveur i produit une table T_i (dans l'algorithme knn). On se sert alors de cette table T_i (toujours dans l'algorithme knn) pour prédire la catégorie d'une étoile en la comparant à toutes les étoiles dans T_i pour trouver ses k plus proches voisins. Si nous avons m serveurs , et chaque serveur i produit une table Ti , alors une super table est une combinaison de m table T_0..m . Ex, 10 serveurs, 10 tables: T1, T2..., T10. SuperTable_10 = T1+T2+..+T10. Quel est le moyen le plus rapide pour calculer une super table? Nous allons utiliser des arbres binaire complet. Où tous les calculs fait à la hauteur d'un arbre sont fait en parallèle. Pour créer un arbre binaire complet, nous pouvons utiliser un algorithme comme le suivant: Algo BinaryTree (serveurs) width <- puissance de deux <= nombre de serveur (exemple dans notre cas 1024, 512 , ...) Branche (serveurs[0..width]) : if |serveurs | > 2 branche gauche = Branche(serveurs[0..|serveurs|/2]) branche droite = Branche(serveurs[|serveurs|/2 ... |serveurs|]) return (branche gauche, branche droite) else branche gauche = serveur[0] branche droite = serveurs[1] return (branche gauche, branche droite)

4. Nous pouvons créer donc des arbres binaire de hauteur 2 (log 2(4)). Biensûre dans notre cas, nous avons d = 23, soit un vecteur de 23 caractéristique! Nous pouvons, réduire la dimensionnalité. Je suis sûr que nous pouvons créer des arbres binaire de hauteur 4 ou plus. Ca fera surement des super tables avec une meilleure précision. Mais , puisque ce n'est pas le but de l'exercice , nous allons nous contenter de super tables produites par des arbres binaire de hauteurs 2.

server 1

T1

binary tree

server 2 server 1

send & write

Pour créer une super table, on a besoin d'une lecture de 750GO, et d'une écriture de 560GO. Puisque cela se fait en parallèle, donc Max(750,560)/3Go/sec = 250 secondes : 4 minutes.

Ensuite, on doit transférer à gauche au total 3 tables de 560 Go (Selon image). 560Go * 3 = 1680Go. 1680Go / 3Gb/s = 560 secondes. 9 minutes.

Une super table (de hauteur 2) met environ 14 minutes à se créer. Puisque nos 256 super tables vont se créer au même temps, elles vont tout se créer en 14 minutes.

2. Chaque serveur Receveur applique l'algo Knn en O(n) et doit donc lire 560 * 4Go = 2240Go . En 2240/ 3Go/s = 746 secondes. Soit 12 minutes et demi.

1. Nos serveurs ont une capacité limitée. Si nous essayons d'écrire toutes nos tables dans un seul serveur, il va peut-être saturer. Milliards de floats dans la table. float = 4 bytes. 4 139,91 M = 559,67 Milliards de bytes. Si on convertis nous avons environ 560 Go. server 1

Tant que le nombre de serveurs est une puissance de deux, on peut le deviser récursivement pour obtenir un arbre binaire complet de hauteur log_2(width). Cela dit, nous ne voulions pas une seule super table (seul arbre binaire), mais plusieurs super tables. 2. Nous avons précédemment discuté sur comment accélérer la prédiction. Si on envoie la requête (d'un vecteur caractérstique c) pour prédire une catégorie à une grosse table, cela va prendre plus de temps. Tandis que si nous envoyons notre requête à Dans notre cas nous avons 1200 serveurs. La plus grande puissance de 2 et plus petite que 1200 est 1024. Puisque à la fin des calculs de notre arbre binaire, notre super table (la combinaison de toutes tables) sera écrite sur un seul serveur. Il est donc Nous savons que nous avons au total 7300 milliards d'étoile répartis de manière balancées dans 1200 serveurs. 7300 Milliards d'étoile par serveur. Et nous avons 23 caractéristiques, donc d=23. Bref, nous avons n d = 139,91 Chaque serveur a une capacité de 4 Tera (soit 4000Go). Et 750Go sont déjà occupée (par les étoiles). Donc, nous avons en réalité 3250 Go. Combien de fois pouvons nous mettre 560 dans 3250? 3250 / 460 = 5,8. Donc, la puissance de deux la plus proche est

send & write server4 server 3 send & write **T4** Combien de super tables de hauteur 2 pouvons nous créer ? Puisque plus on a de super tables, plus on aura de retour sur nos prédictions et donc plus on pourra améliorer notre précision tout en gardant la même rapidité (calculs fait en parallèle).

server 3

Dans le cas où nous avons un seul vecteur caractéristique à prédire : 1. Nous envoyons ce vecteur (instanténement aux 256 serveurs {1,5,...,1021} (Super Tables)) à partir d'un serveur Envoyeur. 2. Chaque serveur Receveur applique l'algo Knn en O(n) et doit donc lire 560 * 4Go = 2240Go . En 2240/ 3Go/s = 746 secondes. Soit 12 minutes et demi. 3. Chaque serveur Receveur renvoie la catégorie prédite (int) instantanément au serveur Renvoyeur qui se retrouve avec un tableau de 256 int. Il calcule instantanément quelle catégorie revient le plus souvent et c'est la réponse qu'on cherche. Dans le cas où nous avons k vecteurs caractéristique à prédire :

1024 premiers serveurs. une fois cela fait, on commence nos calculs en parallèle.

1. Appliquer algo Knn pour produire table dans chaque serveur du niveau i

2. Faire un transfert vers le serveur à gauche dans chaque niveau i 3. Recommencer 2 tant que nous avons pas atteint la racine de l'arbre

Prédiction

Conclusion

lesquelles faire nos prédictions en parallèle!

Avec notre méthode, on cherche l'équilibre entre la performance et la précision. Faire des super tables avec des hauteurs plus que 2 n'est pas une si bonne idée puisque nous avons remarqué que pour seulement 4 tables combinées, c'est 12 minutes "d'entrainement". Biensûre, nous pouvons faire des super tables de hauteur 1 pour réduire le temps de moitié. Ou ne simplement pas utiliser les super tables. Mais cela est au prix d'avoir moins de précision.

1. On devise nos 256 vecteurs par k afin de partager la tâche sur plusieurs super tables. Et chaque (ou le) serveur Envoyeur envoie son (ou ses) vecteur caractéristiques à 256/k serveurs receveur non occupé.

Dans la figure, nous avons utiliser 4 serveurs. Prenons par exemple 1024 serveurs. Nous pouvons donc créer 256 super tables. Les serveurs {1,2..,4}, ..., {1021,1024}. Bref, on crée des arbres binaire de hauteurs 2 en groupant par 4 en ordre nos

C'est ici que ca devient intéressant. Ademettons que nous voulouns prédire la catégorie d'un vecteur caractéristique, ou de plusieurs vecteurs caractéristiques. (Dans les 1200-1024 = 176 serveurs restants). Nous avons devant nous 256 super tables sur

3. Chaque serveur Receveur renvoie la catégorie prédite (int) instantanément au serveur Renvoyeur qui se retrouve avec un tableau de 256/k int. Il calcule instantanément quelle catégorie revient le plus souvent et c'est la réponse qu'on cherche.